

Introduction à la statistique multivariée

Analyser la relation entre deux variables quantitatives

Kadjo Raphaël KOBENAN

Doctorant en Géomatique - Université Le Havre Normandie

Géomaticien aux SDIS 95

krkobenan@parisnanterre.fr

Une introduction...

Dans ce TD, nous allons apprendre à étudier si deux variables numériques sont liées entre elles.

Exemple : Peut-on dire que lorsqu'une personne travaille plus d'heures par semaine, elle gagne plus d'argent ?

Les analyses statistiques ne sont pas toutes pareilles, cela dépend de ce qu'on cherche et des données utilisées.

On distingue deux types principaux :

		VAR. À EXPLIQUER	
		quali	quanti
VAR. EXPLICATIVE	quali		
	quanti		

- ❑ Les méthodes descriptives : elles servent juste à organiser et résumer les données qu'on a, par exemple en faisant des moyennes ou des graphiques.
- ❑ Les méthodes explicatives : elles essaient de comprendre pourquoi une variable change, en utilisant d'autres variables pour l'expliquer.

Démarche générale

1. Poser une hypothèse

Imaginer qu'il existe peut-être une relation entre les deux variables (par exemple, Plus le revenu est élevé, plus les heures de travail sont nombreuses).

La variable heures de travail (Y) change-t-elle quand le variable revenue (X) change ? En d'autres termes, si le revenu augmente ou diminue, est-ce que les heures travaillées augmentent ou diminuent également ? C'est ce qu'on appelle la **covariation**.

2. Créer un tableau de données

Ce tableau va nous aider à vérifier s'il existe un lien entre ces deux éléments.

Exemple :

Personne	Revenu (€)	Heures de travail
1	2000	35
2	2500	40
3	1800	30
4	2200	37

3. Explorer graphiquement

Faire un nuage de points :

- ☐ Axe X = Revenu
- ☐ Axe Y = Heures travaillées

Cela permet de voir si les points semblent alignés (donc liens).

Démarche générale

4. Analyse numérique : la covariance et le coefficient de corrélation

4.1. Qu'est-ce que la covariance ?

- ☐ La covariance montre si deux choses changent ensemble.
- ☐ Si elles changent beaucoup en même temps, c'est qu'elles sont probablement liées.
- ☐ Si elles ne changent pas ensemble, cela veut dire qu'elles sont indépendantes : une peut changer sans que l'autre ne change.

Comment calculer-t-on la covariance ?

- ☐ On calcule d'abord la différence entre chaque valeur et la moyenne pour chaque variable (X et Y).
- ☐ Pour chaque observation (une de X et une de Y), on multiplie ces différences.
- ☐ On fait cela pour toutes les valeurs.
- ☐ Enfin, on fait la moyenne de tous ces produits.

Le résultat est la covariance.

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})$$

où :

- n est le nombre d'observations,
- X_i et Y_i sont les valeurs individuelles des variables X et Y ,
- $\bar{X}$ est la moyenne de X ,
- $\bar{Y}$ est la moyenne de Y .

Démarche générale

4. Analyse numérique : la covariance et le coefficient de corrélation

4.2. À quoi sert le coefficient de corrélation ?


- ❑ Le coefficient de corrélation, appelé aussi « R de Bravais-Pearson », sert à savoir s'il existe une relation linéaire entre deux variables numériques continue.

Comment calculer-t-on le coefficient de corrélation ?

- ❑ Le coefficient de corrélation se calcule en divisant la covariance par le produit des écarts-types des deux variables.

Le signe de R montre la direction de la relation, et sa valeur indique la force de cette relation, c'est-à-dire la capacité à prévoir les valeurs de Y grâce à celles de X.

$$r = \frac{Cov(X,Y)}{\sigma_X \times \sigma_Y}$$



- ❑ r proche de 1 : forte relation linéaire positive entre x et y
- ❑ r proche de -1 : forte relation linéaire négative entre x et y
- ❑ r proche de 0 : pas vraiment de lien entre x et y

Démarche générale

5. Modéliser la relation

Quel modèle va-t-on utiliser pour comparer ce que l'on observe avec ce que prévoit la théorie ?


Pour étudier la relation entre deux variables numériques, il existe plusieurs modèles, mais ici on se limite à la régression ou corrélation linéaire :

Dans cette formule :

$$Y = aX + b$$

- ☐ Y est la variable dépendante, celle qu'on veut prédire et qui dépend de X .
- ☐ X est la variable indépendante, ou explicative, celle qui influence Y .
- ☐ b est l'ordonnée à l'origine (ou intercept), c'est la valeur de Y quand $X = 0$.
- ☐ a est la pente de la droite (ou coefficient de régression), elle mesure de combien Y change quand X change.

Cette relation correspond visuellement à une droite sur un graphique.



Démarche générale

5. Modéliser la relation

Exemple d'application : Exercice 1- TD 2

Une fonction linéaire s'écrit : $Y = aX + b$

Cela veut dire que pour trouver Y, on prend X, on le multiplie par un nombre (a), puis on ajoute un autre nombre (b).

À chaque fois que X change, Y change aussi de manière régulière en fonction des valeurs de a et b.
Par exemple, si $a = 1$ et $b = 0$, alors pour chaque X, Y est égal à X ($y = 1 \times X + 0 = X$).

Pour les 4 premières colonnes, il faut appliquer cette même logique. Pour les 3 dernières colonnes, on utilise d'autres types de fonctions.

		Y1 (a = 1 et b = 0) donc Y1 = 1X+0 = 1*94 + 0 = 94	Y2 (a = 2 et b = 0) donc Y2 = 2X+0 = 2*94 + 0 = 188	Y3 (a = 3 et b = 0) donc Y3 = 3X+0 = 3*94 + 0 = 282	Y4 (a = 2 et b = 50) donc Y4 = 2X+50 = 2*94 + 50 = 238	Y5 = X^2 = 94 * 94 = 8836	Y6 = 1/X = 1 / 94 = 0,01	Y7 = √X = RACINE(94) = 9,70
CODE	X	Y1	Y2	Y3	Y4	Y5	Y6	Y7
OBS01	94	94	188	282	238	8836	0,01	9,70
OBS02	29	29	58	87	109	841	0,03	5,39
OBS03	5	5	10	15	60	25	0,20	2,24
OBS04	18	18	36	54	86	324	0,06	4,24
OBS05	15	15	30	45	80	225	0,07	3,87
OBS06	55	55	110	165	160	3025	0,02	7,42
OBS07	58	58	116	174	166	3364	0,02	7,62
OBS08	79	79	158	237	208	6241	0,01	8,89
OBS09	43	43	86	129	136	1849	0,02	6,56
OBS10	95	95	190	285	240	9025	0,01	9,75
OBS11	4	4	8	12	58	16	0,25	2,00
OBS12	45	45	90	135	140	2025	0,02	6,71
OBS13	63	63	126	189	176	3969	0,02	7,94
OBS14	46	46	92	138	142	2116	0,02	6,78
OBS15	32	32	64	96	114	1024	0,03	5,66
OBS16	34	34	68	102	118	1156	0,03	5,83
OBS17	77	77	154	231	204	5929	0,01	8,77
OBS18	10	10	20	30	70	100	0,10	3,16
OBS19	23	23	46	69	96	529	0,04	4,80
OBS20	88	88	176	264	226	7744	0,01	9,38
OBS21	70	70	140	210	190	4900	0,01	8,37
OBS22	46	46	92	138	142	2116	0,02	6,78
OBS23	42	42	84	126	134	1764	0,02	6,48
OBS24	85	85	170	255	220	7225	0,01	9,22
OBS25	2	2	4	6	54	4	0,50	1,41
OBS26	64	64	128	192	178	4096	0,02	8,00
OBS27	1	1	2	3	52	1	1,00	1,00
OBS28	47	47	94	141	144	2209	0,02	6,86
OBS29	3	3	6	9	56	9	0,33	1,73
OBS30	66	66	132	198	182	4356	0,02	8,12

5. Modéliser la relation

Le coefficient de détermination

Le coefficient de détermination (noté R^2) est simplement le carré du coefficient de corrélation.

Il sert à mesurer à quel point le modèle mathématique, sous la forme $y = aX + b$, arrive à expliquer les variations de la variable Y étudiée.

On exprime souvent R^2 en pourcentage. Par exemple, un R^2 de 0,60 veut dire que le modèle explique 60 % des changements de Y : plus le modèle est bon, plus le pourcentage est élevé.

R^2 varie toujours entre 0 et 1 :

- ❑ Plus R^2 est proche de 1 (ou 100 %), plus Y s'explique bien par X : le modèle fonctionne bien.
- ❑ Plus R^2 est proche de 0, moins Y s'explique par X : le modèle n'est pas adapté.

En résumé, R^2 indique la part de l'information sur Y que l'on peut prédire à partir de X grâce au modèle.

Démarche générale

5. Modéliser la relation

Détecter et éliminer les valeurs exceptionnelles (outliers)


Une valeur exceptionnelle (ou « outlier ») est un chiffre beaucoup plus grand ou beaucoup plus petit que les autres dans un jeu de données.

Ces valeurs se distinguent vraiment des autres et peuvent fausser les résultats ou le modèle. Il est donc parfois nécessaire de les repérer et de les retirer.

Par exemple, si on garde deux valeurs très différentes, elles peuvent donner l'impression qu'il y a une relation linéaire entre les variables, alors qu'en réalité cette relation n'existe pas sans ces valeurs.

Ces « outliers » tirent la droite du graphique, et faussent l'interprétation.

C'est pourquoi, il faut toujours regarder un nuage de points pour repérer facilement les valeurs exceptionnelles : ce sont les points très éloignés de la droite, qui peuvent fausser les résultats.




Démarche générale

5. Modéliser la relation

Détecter et éliminer les valeurs exceptionnelles (outliers)

La relation entre les deux variables a un peu baissé : maintenant, pour 100 personnes, il y a environ 42 emplois.

Le coefficient de détermination R^2 est plus élevé, ce qui signifie que le modèle explique mieux la variation du nombre d'emplois par département lorsqu'on enlève Paris et le 92.



Attention, cette estimation ne prend pas en compte les 3% de variations que le modèle ne peut pas expliquer

6. Les résidus

Résidu en régression linéaire

Un résidu représente la part de la variation de la variable dépendante Y que le modèle ne peut pas expliquer avec la variable indépendante X .

En pratique, ce sont les différences entre les valeurs observées Y_i et les valeurs prédites $\hat{Y}_i$ par la droite de régression.

La formule du résidu e_i pour l'observation i est : $e_i = Y_i - \hat{Y}_i$ où Y_i est la valeur réelle et $\hat{Y}_i$ la valeur estimée par le modèle.

Ces écarts montrent que les points ne sont pas toujours parfaitement alignés sur la droite, car chaque individu peut s'éloigner différemment de la tendance moyenne.

Les résidus servent à vérifier si la droite de régression est vraiment adaptée. Si le graphique des résidus fait apparaître un motif spécial (par exemple une courbe), cela veut dire que le modèle n'est pas bon.

6. Les résidus

Résidu en régression linéaire

Les résidus bruts sont utiles, mais les **résidus relatifs (RR)** permettent une comparaison plus simple entre différentes valeurs.

Le résidu relatif s'obtient en **divisant le résidu brut** par la **valeur prédite** du modèle, et il s'exprime en pourcentage (%).


Interprétation des résidus :

- ☐ Si la valeur observée est inférieure ou en-dessous de la valeur prédite, **le résidu est négatif**.
- ☐ Si la valeur observée est supérieure ou au-dessus de la valeur prédite, **le résidu est positif**.

Comme pour un tableau croisé (contingence), on peut calculer différents types de résidus : **les résidus bruts (RB) et les résidus relatifs (RR)**.

Résumé des formes de nuages de points

Quelques formes de nuages de points



Conclusion

À retenir

- ❑ Une relation statistique montre qu'il y a un lien entre deux variables, mais **cela ne prouve pas que l'une est la cause de l'autre**.
- ❑ Il est important de visualiser les données et de calculer les indicateurs (nuage de points, corrélation, régression).
- ❑ Interpréter les résultats selon le contexte (ne pas se fier uniquement aux chiffres).