

Statistique Univariée

Kadjo Raphael KOBENAN

Géographe,

Ingénieur Géomatique,

Ingénieur Géomarketing,

Doctorant en Géomatique - Université Le Havre Normandie,

Géomaticien aux SDIS 95

raphael.kobenan@gmail.com

Introduction

Résumés Statistiques

Distribution Statistique

Introduction

Résumés Statistiques

Distribution Statistique

Introduction

Tableau d'information géographique et sa signification

En Colonnes : Variables Caractères

En lignes :
Entités
Individus
Objets
Unités

Departements	Nom	Agriculteur	Artisan commerçant	Cadre	Profession intermédiaire	Employé	Ouvrier	Retraité	Autres
01	Ain	4067	16745	36426	70663	77349	78998	30417	29910
02	Aisne	5201	11414	18629	48889	71578	78906	32063	42108
03	Allier	6159	9396	11842	31102	46196	42101	24218	21344
04	Alpes-de-Haute-Provence	2027	6387	6951	16140	20885	15560	10687	10278
05	Hautes-Alpes	2040	5286	5883	15687	19707	12415	8865	7222
06	Alpes-Maritimes	1918	39514	73884	117652	160574	87227	54801	68990
07	Ardèche	4132	10758	12461	31859	39088	37199	21660	19063
08	Ardennes	3362	6520	9771	25487	36326	42618	16464	23226
09	Ariège	2348	4888	5537	14442	20788	16635	10379	9741
10	Aube	4786	7198	12499	28889	40121	43224	18616	18373
11	Aude	5474	12045	13486	31504	47297	34501	25584	25482
12	Aveyron	11100	10116	9937	25717	33970	29390	18550	13039
13	Bouches-du-Rhône	4508	52145	135584	225526	268192	168920	100790	155952
14	Calvados	6081	18540	36155	72740	94384	82643	41776	34559
15	Cantal	7431	4976	4547	12517	19508	17183	10386	7786
16	Charente	5756	10236	14308	32982	46169	46763	24653	20416
17	Charente-Maritime	9061	21025	24906	57199	84800	65577	46140	35151
18	Cher	4025	8183	12967	29897	42604	39209	22057	18361
19	Corrèze	4930	7553	9273	23538	33050	28048	16824	12970
2A	Corse-du-Sud	5352	13503	32185	62097	71854	61993	30098	23303
2B	Haute-Corse	12517	17359	24766	54660	70213	68805	43023	29034
21	Côte-d'Or	5259	3696	3669	9387	16039	12764	9811	6780
22	Côtes-d'Armor	7694	15460	14125	34308	54103	47943	31651	24558
23	Creuse	4123	12196	29138	57994	65018	77588	28449	27692
24	Dordogne	6106	14998	23027	52929	59618	57491	28522	30398

Introduction

La statistique univariée étudie une seule variable à la fois. Une variable, c'est un élément que l'on mesure ou que l'on observe, comme la taille d'une personne, le nombre d'enfants dans une famille, ou la température d'un jour.

Ce cours explique comment décrire, résumer et comprendre une variable grâce à des calculs simples.

Variables et valeurs

Les variables d'un tableau d'information géographique peuvent être quantitatives ou qualitatives.

Une variable qualitative == variable qui décrit une qualité ou une catégorie. On a des valeurs qui ne sont pas des nombres et on ne peut pas faire d'opérations mathématiques comme l'addition avec ces valeurs, **car cela n'aurait pas de sens**. *Ex : Le sexe des étudiants dans une classe (Homme, Femme) ou couleur préférée,*

Les valeurs peuvent être :

- **nominales** (lettres, mots, chiffres, nom).
- **ordinales**, c'est-à-dire qu'on peut les classer dans un ordre (comme 1er, 2ème, 3ème ou bons, moyens, mauvais).

Introduction

Variables et valeurs

Une variable quantitative est une caractéristique que l'on peut mesurer avec un nombre. Ces nombres permettent de faire des calculs comme l'addition ou la moyenne. Par exemple, l'âge, le salaire ou le nombre d'enfants sont des variables quantitatives.

Il existe différents types de variables quantitatives :

- **discrètes** : elles prennent des valeurs entières séparées, comme le nombre de livres qu'un étudiant possède (1, 2, 3, etc.).
- **continues** : elles peuvent prendre n'importe quelle valeur dans un intervalle, comme la taille en mètres (1,65 m, 1,80 m, etc.).

Introduction

Variables et valeurs

Autres types de variables quantitatives et échelles:


- **Variables de stock** : elles mesurent des quantités concrètes, comme la production d'une parcelle ou la dette d'un pays.
- **Variables de taux** : elles expriment un rapport en pourcentage, comme le taux de chômage ou le pourcentage de réussite scolaire.
- **Variables sur une échelle où zéro n'est pas $\varnothing$ rien E (repérable)**: ce sont des mesures où zéro est juste un point de référence, mais ça ne veut pas dire qu'il n'y a rien. Par exemple, la latitude ou la température.
- **Autres variables sur une échelle où zéro veut dire $\varnothing$ rien E (mesurable)** : ce sont des mesures où zéro signifie vraiment qu'il n'y a rien, comme la population d'un lieu ou le niveau de risque.

NB : Les variables quantitatives de stock et de taux sont les plus utilisées en cartographie pour diviser les données en classes homogènes lors de la discrétisation.

Introduction

Variables et valeurs

Les différents types de caractères/ variables



Introduction

Variables et valeurs

De quels types (qualitatif ordinal, qualitatif nominal, quantitatif) sont les caractères suivants

Identifiant	Nom	Population en 2011	Typologie des pays	Taux de chômage au 05/12	Classement mondial selon le PIB en 2011	Appartenance à l'UE (UE = 1, hors UE = 0)
1	France	65048412	Grand	10,1	5	1
2	Belgique	10951665	Moyen	7,2	23	1
3	Suisse	7866500	Petit	3,0	19	0

Correction :

- **Quantitatif** : Population, Taux de chômage.
- **Qualitatif nominal** : Identifiant, Nom, Appartenance à l'UE.
- **Qualitatif ordinal** : Typologie des pays, Classement mondial selon le PIB

Dans ce cours, on va étudier les variables quantitatives. Ce sont des nombres qui représentent des quantités, comme le nombre de personnes. On peut faire toutes sortes de calculs avec ces nombres.

Introduction

Résumés Statistiques

Distribution Statistique

Résumés statistiques

Mesures de tendance centrale

Quand on a beaucoup de données, il faut les résumer pour comprendre rapidement ce qu'elles montrent.

Les mesures de tendance centrale == pour savoir où sont les données en moyenne

- ❑ **La moyenne** ($\bar{x} = \frac{1}{N} \times \sum_{i=1}^N x_i$): c'est la somme de toutes les valeurs divisées par le nombre total de valeurs.
- ❑ **La médiane** : c'est la valeur qui partage les données en deux parties égales, la moitié est au-dessus, l'autre en dessous.
- ❑ **Le mode** : c'est la valeur qui revient le plus souvent.

Exemple : Si aux âges suivants : 20, 22, 22, 24, 28

- ❑ Moyenne = $(20+22+22+24+28) / 5 = 23,2$ ans
- ❑ Si nombre n d'éléments est impair → Médiane $(n+1)/2 = (5+1) / 2 = 22$ ans (la 3e valeur quand elles sont triées)
- ❑ Si âges suivants : 20, 22, 24, 28. Si nombre n d'éléments est pair → Médiane = moyenne des deux valeurs du milieu $[(n/2 ; (n/2)+1)/2]$. Donc, Médiane = $(22 + 24) / 2 = 23$ ans.
- ❑ Mode = 22 ans (c'est l'âge qui revient le plus souvent)

Résumés statistiques

Mesures de dispersion

- ❑ **L'étendue** = différence entre la valeur la plus grande (max) et la plus petite (min). (*Ex : Pour les âges 18, 19, 20, 21, 22. Etendue == 22 - 18 = 4 ans*).
- ❑ **La Variance** ($v_x = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$) mesure la dispersion des valeurs par rapport à la moyenne. **Variance** == moyenne des carrés des écarts entre chaque valeur et la moyenne. **Ex** : Pour les âges 18, 20, 22, la moyenne est 20. Les écarts à la moyenne sont -2, 0, 2. La variance est $(-2^2 + 0^2 + 2^2) / 3 = 8/3 = 2,67$.
- ❑ **L'écart-type** ($\sigma_x = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2}$) = racine carrée de la variance, elle est dans la même unité que les données. Il exprime la dispersion des données autour de la moyenne. Comme son nom l'indique, c'est un écart, il peut être comparé à la moyenne. **Ex**: L'écart-type $\sqrt{2.67} = 1,63$ ans
- ❑ **Coefficient de variation** = mesure relative de dispersion, souvent exprimée en pourcentage (rapport entre l'écart-type et la moyenne → $CV = \text{Ecart-type} / \text{Moyenne}$).

Introduction

Résumés Statistiques


Distribution Statistique

Distribution Statistique

Définition

La distribution statistique (ou distribution des fréquences) montre comment les données sont réparties. On peut la représenter sous forme d'histogramme (graphique qui montre combien de fois les valeurs différentes apparaissent). C'est une classification des données en catégories de taille égale.


La forme dépend du nombre de classes et de leur taille. Si beaucoup de valeurs sont concentrées autour d'une moyenne, on parle de distribution $\mathcal{P}$ normale E.



Le nombre de classes cherche à trouver un équilibre entre la simplification de la forme et son exactitude.

Distribution Statistique

Les différentes formes de distribution





Valeur centrale	Type de distribution	Exemple
Moyenne = Médiane = Mode	Symétrique ou Normale	Taille des habitants d'une commune
Moyenne > Médiane > Mode	Ptirée ou Ptalée à droite /asymétrie positive.	Population par βge des pays vieillissants (Pologne).
Moyenne < Médiane < Mode	Ptirée ou Ptalée à gauche/ asymétrie négative.	Salaire, tailles des villes, population des pays du monde...
Deux pics distincts. Moyenne # médiane # mode sauf si distribution symétrique ou est influencée par l'un des modes.	Bimodale	La dérive des continents, durée du trajet domicile-travail dans une grande ville, répartition des tailles dans une population mixte (hommes et femmes)

On parle aussi de distribution dissymétrique/asymétrique à droite/gauche

Distribution Statistique

Résumer l'information par les valeurs centrales

1	Maurice	15
2	Tunisie	21
3	Libye	26
4	Cap Vert	28
5	Algérie	30
6	Égypte	33
7	Maroc	40
8	Namibie	44
9	Afrique du Sud	54
10	Botswana	56
11	Gabon	57
12	Ghana	59
13	Érythrée	61
14	Sénégal	61
15	Zimbabwe	61
16	Soudan	64
17	Tanzanie	68
18	Cameroun	74
19	Mauritanie	74
20	Swaziland	74
21	Congo	75
22	Gambie	75
23	Malawi	76
24	Éthiopie	78
25	Kenya	77
26	Burkina Faso	81
27	Ouganda	81
28	Madagascar	83
29	Rwanda	86
30	Togo	90
31	Lésotho	91
32	Zambie	92
33	Cote d'Ivoire	94
34	Congo dém.	95
35	Guinée	98
36	Nigeria	100
37	Tchad	101
38	Bénin	102
39	Guinée Equat.	102
40	Côte d'Ivoire	104
41	Burundi	106
42	Mozambique	108
43	Somalie	119
44	Mali	130
45	Angola	133
46	Liberia	142
47	Niger	143
48	Sierra Leone	163



Distribution
dissymétrique
à gauche
 $\text{Médiane} < \text{Moyenne}$

Le simple calcul de la moyenne et de la médiane permet de conclure de la symétrie ou non de la distribution

Conclusion

Résumé

- La statistique univariée concerne l'analyse et la description des données d'une seule variable.
- Elle permet de décrire et de résumer les caractéristiques principales d'une variable pour mieux comprendre sa distribution, sa tendance centrale, et sa dispersion.
- Ce cours couvre les éléments essentiels de l'analyse univariée en statistiques. Pour approfondir cette compréhension, il est utile de pratiquer avec différents jeux de données et d'explorer comment ces mesures peuvent varier d'un ensemble de données à un autre.

Aller plus loin

Bien que la statistique univariée soit une base solide, elle ne suffit pas toujours à répondre à des questions plus complexes. L'exploration de techniques d'analyse multivariée peut alors s'avérer nécessaire pour obtenir une compréhension plus approfondie de nos données.

Conclusion

Voici quelques suggestions de sources de données statistiques accessibles gratuitement

À l'échelle des pays du monde

- Centralisation de données sur le développement économique, des indicateurs de santé (OMS), de production agricole et alimentaire (FAO) par l'Organisation des Nations Unies, certaines sont téléchargeables gratuitement sur : <https://data.un.org/>

À l'échelle des régions et des pays de l'Union Européenne

- Centralisation des données par Eurostat à l'échelle NUTS_2 (équivalent aux régions françaises) et NUTS_3 (équivalent aux départements français) certaines sont téléchargeables gratuitement sur : <https://ec.europa.eu/eurostat/fr/web/main/data/statistical-themes>

À l'échelle des communes et des départements français

- La plupart des données socio-économiques sont diffusées par l'INSEE, BRGM pour la géologie, Météo- France pour la climatologie, INRA-SOLS pour la pédologie, IFREMER pour les ressources marines, IFN pour les forêts, etc. Les métropoles se dotent d'outils pour ouvrir leurs données en Opendata en regroupant différentes sources de données.